



数值分析 (5)

Numerical Analysis

第五章 矩阵特征值问题

- 矩阵特征值与特征向量的计算: \in 数值线性代数, 矩阵计算(matrix computation)的重要内容
- 矩阵特征值=特征多项式方程的解 \longrightarrow 一定是迭代解法
- 本章内容
 - 基本概念与特征值的分布
 - 幂法与反幂法
 - 矩阵的正交三角化, **QR**分解
 - 计算所有特征值的**QR**迭代算法





矩阵特征值的基本概念

基本概念

- 矩阵 A 的**特征值**与**特征向量**, (A 为方阵)

$$Ax = \lambda x$$

- 特征值 λ 是**特征方程**的根, 复数域内有 n 个(含重根)

$$\det(\lambda I - A) = \begin{vmatrix} \lambda - a_{11} & -a_{12} & \cdots & -a_{1n} \\ -a_{21} & \lambda - a_{22} & \cdots & -a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ -a_{n1} & -a_{n2} & \cdots & \lambda - a_{nn} \end{vmatrix} = 0$$

- **特征值谱**: $\lambda(A)$
- 给定一特征值 λ , 特征向量是方程 $(\lambda I - A)x = 0$ 的**非零解**
- 对任一特征值, 特征向量都不唯一, 构成**特征子空间**
- 假设 $A \in \mathbb{R}^{n \times n}$, (1)**特征值不一定是实数**; (2)**实特征值一定对应实特征向量**; (3)**非实特征值的共轭也是特征值**, 其对应的特征向量一定不是实向量

特征值的有关性质

- 非奇异矩阵特征值均不为0; 0一定是奇异矩阵的特征值
- Th5.2 ■ $\lambda(A) = \lambda(A^T)$ $\det(\lambda I - A) = \det((\lambda I - A)^T)$
- Th5.3 ■ 若A为对角阵或上(下)三角阵, 则其特征值为其对角元
- Th5.4 ■ 若A为分块对角阵或分块上(下)三角阵(对角块为方阵), 则 $\lambda(A) = \bigcup_{j=1}^m \lambda(A_{jj})$
- Th5.5 ■ 相似矩阵的特征值相等 $A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ & A_{22} & \cdots & A_{2m} \\ & & \ddots & \vdots \\ & & & A_{mm} \end{bmatrix}$
 $B = X^{-1}AX$
- Th5.9 ■ 矩阵运算结果的特征值: 设 λ_j 为A的特征值, 则
 $\lambda(cA) = \{c\lambda_j\}$; $\lambda(A + cI) = \{\lambda_j + c\}$; $\lambda(A^k) = \{\lambda_j^k\}$; $\lambda(A^{-1}) = \{\lambda_j^{-1}\}$;
- **定义5.2** 设 $A \in \mathbb{R}^{n \times n}$ 有m个($m \leq n$)不同的特征值 $\tilde{\lambda}_1, \dots, \tilde{\lambda}_m$, 若 $\tilde{\lambda}_j$ 是特征方程的 n_j 重根, 则称 n_j 为 $\tilde{\lambda}_j$ 的代数重数, 而 $\tilde{\lambda}_j$ 的特征子空间的维数其几何重数.

特征值的有关性质

- 设 n 阶方阵 A 的 m 个不同的特征值为 $\tilde{\lambda}_1, \dots, \tilde{\lambda}_m$, $\tilde{\lambda}_j$ 的代数重数为 n_j , 几何重数为 k_j , 则

Th5.6 □ $\sum_j n_j = n; \forall j, n_j \geq k_j$

- 不同特征值的特征向量线性无关, 所有特征子空间的 $\sum_{j=1}^m k_j$ 个基形成一组线性无关向量

定义5.3

- 若 $\forall j, n_j = k_j$, 这种矩阵 A 为**非亏损阵**, 否则为**亏损阵**

非亏损阵有 n 个特征向量构成全空间的基 (\mathbb{C}^n) (特征值分解)

- **Th5.7:** $\exists X^{-1}AX = \Lambda$, Λ 为对角阵 $\Leftrightarrow A$ 为非亏损阵

- 实对称阵非亏损, 且特征值为实数 (可正交对角化)

- **Th5.8**(Jordan分解): $A = XJX^{-1}$, $\tilde{\lambda}_j$ 的几何重数为 k_j , $p = \sum k_j$, $\tilde{\lambda}_j$ 对应 k_j 个约当块, 其阶数之和 = n_j

特征值的分布

■ Motivation

□ 迭代法 $x^{(k+1)} = Bx^{(k)} + f$ 的收敛性, 看 $\rho(B) = \max_j |\lambda_j(B)|$

□ 矩阵的2-范数、2-条件数: $\text{cond}(A)_2 = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}}$


■ $\rho(A) \leq \|A\|$ 是关于特征值上界的重要结论

■ **定义5.4** 对于复矩阵 A , 设 $r_k = \sum_{j=1, j \neq k}^n |a_{kj}|$, 在复平面上以 a_{kk} 为圆心、 r_k 为半径的圆, 称为 A 的 **Gerschgorin 圆盘**

■ **Th5.10** (圆盘定理) 思考: 如何证明?

□ A 的特征值必在某个圆盘上


□ 若 n 个圆盘中有 m 个连通, 且与其他分离, 则这 m 个圆盘恰包含 m 个特征值



[交互演示网站](#)


圆盘定理的应用

- **Th5.11** 严格对角占优阵, 正对角元, $\text{Re}(\lambda) > 0$
若 \mathbf{A} 为对角占优的对称阵, 则...



- **例:** 估计矩阵 $A = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 0 & -1 \\ 1 & 1 & -4 \end{bmatrix}$ 的特征值分布

- 直接应用圆盘定理, D_1 与其他两个分离, 必含一个实特征值
- 再对 A^T 应用圆盘定理, D'_3 与其他圆盘分离, 必含一实特征值



- $\lambda_1 \in [3, 5], \lambda_2 \in [-2, 2], \lambda_3 \in [-5, -3]$
- 准确特征值为: 4.2030, -0.4429, -3.7601
- 还可先做简单的相似变换, 再估计分布, 见pp.153, 例5.4



幂法与反幂法

计算最大的特征值、特征向量

- **定义5.5** 模最大的特征值称为**主特征值**, 也叫“第一特征值”, 它对应的特征向量称为**主特征向量**
- 主特征值可能**不唯一**, 例如 $5, -5, 3 + 4i, 3 - 4i$ 的模都是**5**
- **幂法**(power iteration): 取任意非零向量 \boldsymbol{v}_0 , 计算 $\boldsymbol{v}_k = A\boldsymbol{v}_{k-1}, (k = 1, 2, \dots)$, 得到向量序列 $\{\boldsymbol{v}_k\}$
- 看一个例子: $A = \begin{bmatrix} 5 & -1 & -1 \\ 3 & 1 & -1 \\ 4 & -2 & 1 \end{bmatrix}$ (pp. 148, 例5.2, 其主特征值为3)
- 取 $\boldsymbol{v}_0 = [1, 0, 0]^T$, 利用Matlab算向量序列 $\{\boldsymbol{v}_k\}$ [Matlab demo](#)
- 通过实验看出: 相邻两个 \boldsymbol{v}_k 逐渐呈倍数关系, 倍数为**3**
- \boldsymbol{v}_k 趋近于**3**对应的特征值向量 [更多例子:
交互演示网站](#)

幂法

- 幂法是否总能计算矩阵的主特征值？

- **定理5.12** 若矩阵 A 有**唯一**的主特征值 λ_1 , 向量 \mathbf{v}_0 非零, 计算 $\mathbf{v}_k = A\mathbf{v}_{k-1}, (k = 1, 2, \dots)$, 则一般有

$$\lim_{k \rightarrow \infty} \frac{(\mathbf{v}_{k+1})_j}{(\mathbf{v}_k)_j} = \lambda_1 \quad \lim_{k \rightarrow \infty} \frac{\mathbf{v}_k}{\lambda_1^k} = \mathbf{x}_1 \quad \text{条件: } \lambda_1 \text{ 的几何重数等于代数重数}$$

\mathbf{x}_1 为某个主特征向量, j 的取值须保证有 \mathbf{x}_1 使 $(\mathbf{x}_1)_j \neq 0$

- **证明:** 设 A 非亏损阵, 且 λ_1 不是重特征值, $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ 设 A 的线性无关的单位特征向量为 $\hat{\mathbf{x}}_1, \dots, \hat{\mathbf{x}}_n$, $\mathbf{v}_0 = \alpha_1 \hat{\mathbf{x}}_1 + \dots + \alpha_n \hat{\mathbf{x}}_n$

$$\mathbf{v}_k = A^k \mathbf{v}_0 = \alpha_1 \lambda_1^k \hat{\mathbf{x}}_1 + \dots + \alpha_n \lambda_n^k \hat{\mathbf{x}}_n = \lambda_1^k \left[\alpha_1 \hat{\mathbf{x}}_1 + \sum_{j=2}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k \hat{\mathbf{x}}_j \right]$$

$\therefore \lim_{k \rightarrow \infty} \frac{\mathbf{v}_k}{\lambda_1^k} = \alpha_1 \hat{\mathbf{x}}_1 \xrightarrow{\text{对 } j \text{ 的取值要求}} \lim_{k \rightarrow \infty} \frac{(\mathbf{v}_{k+1})_j}{(\mathbf{v}_k)_j} = \lambda_1$

思考: 若 $\alpha_1 = 0$ 呢?

幂法

$$\boldsymbol{v}_k = A\boldsymbol{v}_{k-1}$$

特殊情况: \boldsymbol{v}_0 不能为某特征向量!

■ 关于幂法的说明

- A 为亏损矩阵的情况, 用矩阵的 Jordan 标准型进行证明?
- $\{\boldsymbol{v}_k\}$ 相邻项的第 j 分量的比值 \rightarrow 主特征值, 选 j 为最大分量
- 证明中假设了 $\alpha_1 \neq 0$, 在实际应用时可随机选取 \boldsymbol{v}_0

■ 关于幂法的问题

$\boldsymbol{v}_k \approx \lambda_1^k \boldsymbol{x}_1$, k 很大时, 可能出现上溢或下溢

$$\boldsymbol{v}_k = \lambda_1^k \left[\alpha_1 \hat{\boldsymbol{x}}_1 + \sum_{j=2}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k \hat{\boldsymbol{x}}_j \right], \text{ 收敛速度主要取决于 } \left| \frac{\lambda_2}{\lambda_1} \right|$$

■ 实用的幂法: 用规格化向量的技术防止溢出

- **定义 5.6** 记 $\overline{\max}(\boldsymbol{v})$ 为向量 \boldsymbol{v} 的绝对值最大分量, 若不唯一则取最小编号的那个. 称 $\boldsymbol{u} = \boldsymbol{v} / \overline{\max}(\boldsymbol{v})$ 为向量 \boldsymbol{v} 的规格化向量

实用的幂法

■ 规格化向量

- 例: $v = [3, -5, 0]^T$, $\overline{\max}(v) = -5$, 规格化向量为 $u = \left[-\frac{3}{5}, 1, 0\right]^T$
- 若 u 为规格化向量, 则 $\|u\|_\infty = 1$, $\overline{\max}(u) = ?$
- 向量 v_1, v_2 的规格化向量分别为 u_1, u_2 , 若 $v_1 = \alpha v_2$, 则 $u_1 = u_2$

■ 在幂法的每步增加向量规格化操作

$$\begin{aligned} v_1 &= Av_0 \xrightarrow{\text{规格化}} \text{规格化向量 } u_1 = \frac{v_1}{\overline{\max}(v_1)} = \frac{Av_0}{\overline{\max}(Av_0)} \\ v_2 &= Au_1 = \frac{A^2 v_0}{\overline{\max}(Av_0)} \xrightarrow{\text{规格化}} \text{规格化向量 } u_2 = \frac{v_2}{\overline{\max}(v_2)} = \frac{A^2 v_0}{\overline{\max}(A^2 v_0)} \\ \begin{cases} v_k = Au_{k-1} = \frac{A^k v_0}{\overline{\max}(A^{k-1} v_0)} \\ u_k = \frac{v_k}{\overline{\max}(v_k)} = \frac{A^k v_0}{\overline{\max}(A^k v_0)} \end{cases}, k = 1, 2, \dots \xrightarrow{\text{规格化}} \begin{cases} \lim_{k \rightarrow \infty} \overline{\max}(v_k) = \lambda_1 \\ \lim_{k \rightarrow \infty} u_k = \frac{x_1}{\overline{\max}(x_1)} \end{cases} \end{aligned}$$

定理5.14 (只需主特征值唯一)

实用的幂法

- **算法5.1**: 计算主特征值 λ_1 和主特征向量 x_1 的实用幂法

输入: v, A ; 输出: x_1, λ_1 .

$u := v$;

While 不满足判停准则 **do**

$v := Au$;

$\lambda_1 := \overline{\max}(v)$; {主特征值近似值}

$u := v/\lambda_1$; {规格化}

End

$x_1 := u$. {规格化的主特征向量}

每步的主要计算
是算一次矩阵与
向量乘法

若 A 为稀疏矩阵,
很容易提高效率


- 用相邻两步特征值近似值之差作为判停准则
- 保证向量的值不溢出, 绝对值最大分量收敛到主特征值
- 适用范围: 主特征值唯一

加速幂法的收敛

■ 原点位移技术

- $B = A - pI$ 的特征值为 A 的特征值 $-p$ 对 B 应用幂法可能加快收敛

- 如图中 A 的特征值分布, $\left| \frac{\lambda_2(B)}{\lambda_1 - p} \right|$ 较小, 因此更快算出 λ_1



■ 瑞利商(Rayleigh quotient)加速

- 实对称矩阵 A 的瑞利商: $R(x) = \frac{\langle Ax, x \rangle}{\langle x, x \rangle} = \frac{x^T A x}{x^T x}$

Th5.15 □ 对实对称阵 A , $\lambda_n \leq R(x) \leq \lambda_1$, $\lambda_1(\lambda_n)$ 为最大(最小)特征值; 若 x 为相应特征向量, 上式取等号 证明中利用“实对称阵可正交对角化”

Th5.16 □ 结合幂法, 加速特征值的收敛: 每步对 u_k 计算 $R(u_k)$

- 每步仅多计算两次向量内积 自己看课本pp. 158-159

反幂法

- A^{-1} 的特征值是 A 特征值的倒数, 对 A^{-1} 应用幂法得最小特征值

算法5.2 计算最小特征值与特征向量的反幂法

输入: v, A ; 输出: x_n, λ_n .

$u := v$;

While 不满足判停准则 **do**

$v := A^{-1}u$; {求解线性方程组}

$\lambda_n := 1/\overline{\max}(v)$; {最小特征值的近似值}

$u := \lambda_n v$; {规格化}

End

$x_n := u$. {规格化的特征向量}

求解线性方程组, 计算量可能比幂法大很多

- 适用范围: A 按模最小的特征值唯一
- 与原点位移技术结合: 若已知某个特征值 $\lambda_j \approx p$, 则 $\lambda_j - p$ 是 $B = A - pI$ 按模最小的特征值, 对 B 使用反幂法 可用瑞利商加速

小结

■ 实用幂法可能失败的情况

- 矩阵 A 的主特征值不唯一, 例如实矩阵, 模最大的特征值不是实数
- 初始向量在主特征向量方向没有分量 (通常没问题)
- 反幂法的情况类似

■ 说明几点

- 按幂法迭代计算, 若前后两次迭代向量成比例, 则它一定就是特征向量, 也相应求出特征值
- 加速幂法的方法还有Aitken外推等算法
- 反幂法结合位移技术, 以及瑞利商加速, 也很有用

应用实例: PageRank™的计算

■ Google网络搜索

- PageRank技术是其创立之初的**关键创新**之一
- 搜索分两步: **找到匹配关键词的网址, 排序显示**
- L. Page和S. Brin于1998年提出PageRank算法
- 给出网页信息可靠/重要性的指标(PageRank)
- 怎样的网页PageRank高? 被推荐, 被**链接到**


■ 数学模型

- n : 网页的总数, $G = (g_{ij})_{n \times n}$: 网页链接矩阵

- 若网页 j 链接到网页 i , 则

$g_{ij} = 1$, 否则 $g_{ij} = 0$

$$G = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix}$$



大规模、非对称、稀疏阵

应用实例: PageRank™的计算

■ 数学模型 (续)

- G 的列元素之和 $c_j = \sum_i g_{ij}$, 等于网页 j 的“出度”
- 访问网页的**Markov**过程, 到达网页的极限概率定义为它的PageRank (按概率 p 沿**链接**跳, 按概率 $1-p$ **随便**跳)
- 设当前在网页 j 、下一步到网页 i 的条件概率为 a_{ij} :
 - i 在 j 的链接上: $p \cdot 1/c_j + (1-p) \cdot 1/n$ $\xrightarrow{\text{乘 } g_{ij}}$
 - i 不在 j 的链接上: $(1-p) \cdot 1/n$ $\xrightarrow{\text{乘 } (1-g_{ij})}$
$$a_{ij} = \frac{p g_{ij}}{c_j} + \frac{1-p}{n}$$
- a_{ij} 组成**转移概率矩阵** A : $A = pGD + \frac{1-p}{n} \mathbf{e}\mathbf{e}^T$ (若不存在 $c_j=0$ 情况)
- 若有 $c_j = 0$ 呢? $a_{ij} = 1/n$, 修改 A 相应的列
- 设 $\mathbf{x}^{(k)}$ 为第 k 次跳转后在各个网页的概率,
则 $\mathbf{x}^{(k+1)} = A\mathbf{x}^{(k)}$ 为再跳一次后在各网页的概率

应用实例: PageRank™的计算

■ 数学模型(续)

- PageRank: 随机”冲浪”过程访问网页的**极限**概率

$$x^{(k+1)} = Ax^{(k)} \quad \lim_{k \rightarrow \infty} x^{(k)} = ? \quad \text{它存在吗?}$$

■ 上述算法(幂法)的理论分析

- 数学本质: 求**1**对应的特征向量 x

$$\begin{cases} Ax = x \\ \sum_{i=1}^n x_i = 1 \end{cases}$$

- 矩阵 A 的特点: $a_{ij} > 0$, 每列元素之和均为**1**


- $\rho(A) \leq 1$; $A^T e = e \xrightarrow{\text{绿色}} 1$ 是主特征值

- 可放心地用幂法

唯一主特征值

- PageRank反映超链接结构, 隔一段时间需重新计算

- 计算中不需对 $x^{(k)}$ 规格化; 实际编程时不形成矩阵 A






矩阵的QR分解

Householder变换

■ 矩阵的正交三角化

- 高斯消去过程
- 可用正交阵来乘吗?
- 是计算所有特征值的算法的基础



■ Householder矩阵

- **定义5.8** $w \in \mathbb{R}^n$ 且 $w^T w = 1$, 称 $H(w) = I - 2ww^T$ 为 Householder **矩阵** (初等反射阵)

- $H(w) = H(-w)$
- H 为对称阵、正交阵 $H =$
- Hx 实现 **Householder变换**

$$\|w\|_2 = 1$$

Householder变换

交互演示5.4

■ Householder变换的几何意义


□ Hx : 以 w 为法向画出超平面 S

$$Hx = (I - 2ww^T)x = x - 2ww^Tx$$

$$ww^Tx = (w^Tx)w = v \xrightarrow{\text{绿色箭头}} Hx = x - 2v$$

□ Hx 为 x 关于平面 S 的镜像 (初等反射变换)

□ Hx 与 x 的2-范数相等, 属于正交变换



■ **Th5.18** 设 $x, y \in \mathbb{R}^n, x \neq y, \|x\|_2 = \|y\|_2$, 则存在Householder矩阵 H , 使 $Hx = y$

■ 几何的启示: $v = x - y, w = v/\|v\|_2$, 构造矩阵 H

■ **Th5.19** 可将Th5.18中的 y 设为 $\begin{bmatrix} \pm\|x\|_2 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \equiv -\sigma e_1$ 用正交变换实现消元!

构造 H 时, $v = x + \sigma e_1$
 $\therefore \sigma = \text{sign}(x_1)\|x\|_2$

Householder变换

■ Householder变换

- 对向量做正交变换实现消元, 结果 $-\sigma e_1$ 中的负号是为了数值稳定
- 例: 确定一个Householder变换, 对向量实现消元操作

$$a = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} \longrightarrow \begin{bmatrix} * \\ 0 \\ 0 \end{bmatrix}$$

$$\text{解: } \sigma = \text{sign}(a_1) \|a\|_2 = 3, \text{ 构造 } v = a + \sigma e_1 = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 3 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix}$$

取 $w = v / \|v\|_2$, 则实现变换的矩阵为 $H = I - 2ww^T$

$$\text{验证: } Ha = a - 2(w^T a)w = a - 2 \frac{v^T a}{v^T v} v = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} - 2 \times \frac{15}{30} \times \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix}$$



很重要! 用向量 v 或 w 表示矩阵 H , 只算向量内积

矩阵的QR分解

■ 用Householder变换实现正交三角化？

- $H_k \cdots H_2 H_1 A = R$
- $A \in \mathbb{R}^{m \times n}$ 不一定是方阵，上三角阵 R 也同样

$m > n$ 的情况:



- $A = H_1 H_2 \cdots H_k R = QR$, 其中 Q 为正交阵, 称为**QR分解**
 - 还有其他正交变换消元的手段: **Givens旋转变换**, 后面将介绍.
- Th5.20** 对任意实矩阵 A , 一定存在QR分解;
若 A 为方阵, 且要求 R 的对角元都 > 0 , 此分解唯一.

矩阵的QR分解

交互演示5.5

■ 用Householder变换实现: $H_k \cdots H_2 H_1 A = R$

□ 设 $A \in \mathbb{R}^{m \times n}$, $m \geq n$, $A = [a_1, a_2, \dots, a_n]$, 其中 a_j 为 m 维向量

构造 m 阶反射阵 H_1

消 A 的第1列:

$$A^{(2)} = H_1 A = \begin{bmatrix} -\sigma_1 & a_{12}^{(2)} & \cdots & a_{1n}^{(2)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{m2}^{(2)} & \cdots & a_{mn}^{(2)} \end{bmatrix} = \begin{bmatrix} -\sigma_1 & | & & | \\ 0 & H_1 a_2 & \cdots & H_1 a_n \\ \vdots & | & & | \\ 0 & | & & | \end{bmatrix}$$

用 H_2 实现 $A^{(2)}$ 第2列的消元, 同时不影响第1列

$$\text{令 } H_2 = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & H'_2 \end{bmatrix} \quad H_2 A^{(2)} = \begin{bmatrix} -\sigma_1 & r_1^T \\ \mathbf{0} & H'_2 A'^{(2)} \end{bmatrix} = \begin{bmatrix} -\sigma_1 & r_1^T \\ 0 & -\sigma_2 & | & \\ 0 & 0 & H'_2 a_2'^{(2)} & \cdots & H'_2 a_{n-1}'^{(2)} \\ \vdots & \vdots & | & & | \\ 0 & 0 & | & & | \end{bmatrix}$$

$$\text{记 } A^{(2)} = \begin{bmatrix} -\sigma_1 & r_1^T \\ \mathbf{0} & A'^{(2)} \end{bmatrix}$$

构造 H'_2

H_2 也是Householder阵(其向量 v 的第一个分量为0). 后续 H_j 可类似构造

算法5.3: 基于Householder变换的矩阵正交三角化

输入: $A = [a_1, a_2, \dots, a_n]$; 输出: $A; v_1, v_2, \dots, v_n$.

For $k=1, 2, \dots, n$

$\sigma_k := \text{sign}(a_{kk}) \sqrt{\sum_{j=k}^m a_{jk}^2}$; {下三角部分第k列的2-范数}

If $\sigma_k = a_{kk}$ then {第k列对角线下方已经全为0}

Continue with next k;

End

$v_k := [0, \dots, 0, a_{kk}, \dots, a_{mk}]^T + \sigma_k e_k$; {构造 H_k 的向量}

$\beta_k := v_k^T v_k$;

For $j=k, k+1, \dots, n$ {对剩余各列作Householder变换}

$\gamma_j := v_k^T a_j$;

$a_j := a_j - (2\gamma_j/\beta_k)v_k$; { $H_k a_j^{(k)} = a_j^{(k)} - 2(v_k^T a_j^{(k)}/v_k^T v_k)v_k$ }

End

Matlab: $[Q,R] = \text{qr}(A)$;

End

$R = \text{qr}(A)$


- 算法执行完, A 变成 R , 得到构造 H_1, H_2, \dots, H_k 所需的 v 向量
- 总的乘法次数: $(2n+1) \cdot m + (2n-1) \cdot m + \dots + 3m \approx mn^2$
- 若考虑 v 向量的稀疏性, 总的乘法次数为 $mn^2 - n^3/3$? 思考

Givens旋转变换

■ 二维平面旋转变换

- 将向量 x 顺时针旋转 θ 角度后得到 y

$$y = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} x$$



- **定义**二阶Givens矩阵为: $G = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}$, 其中 $c = \cos\theta, s = \sin\theta$

- G 是正交阵 (几何解释)

- 对 x 做Givens旋转得 Gx , 选择参数 c, s , 可使 $Gx = \begin{bmatrix} * \\ 0 \end{bmatrix}$

■ n阶Givens旋转阵

将二阶Givens阵
嵌入n阶单位阵:

- G 仍是正交阵

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & c & 0 & s & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & -s & 0 & c & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} x_1 \\ \alpha \\ x_3 \\ 0 \\ x_5 \end{bmatrix}$$

$$c = \frac{x_2}{\sqrt{x_2^2 + x_4^2}}, \quad s = \frac{x_4}{\sqrt{x_2^2 + x_4^2}}$$

Givens旋转变换

- **例:** 通过Givens旋转变换进行消元

解: 先针对第1, 3分量构造二阶旋转矩阵,

$$a = \begin{bmatrix} 2 \\ 0 \\ 1 \\ 2 \end{bmatrix} \xrightarrow{\text{green arrow}} \begin{bmatrix} * \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$$G'_1 = \begin{bmatrix} c_1 & s_1 \\ -s_1 & c_1 \end{bmatrix} \quad c_1 = \frac{2}{\sqrt{2^2 + 1}} = 2/\sqrt{5}, \quad s_1 = 1/\sqrt{5}$$

则: $G_1 a = \begin{bmatrix} c_1 & 0 & s_1 & 0 \\ 0 & 1 & 0 & 0 \\ -s_1 & 0 & c_1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} \sqrt{5} \\ 0 \\ 0 \\ 2 \end{bmatrix}$ 接着对第1, 4分量旋转

求出 $c_2 = \sqrt{5}/3, s_2 = 2/3$, $G_2 G_1 a = \begin{bmatrix} c_2 & 0 & 0 & s_2 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ -s_2 & 0 & 0 & c_2 \end{bmatrix} \begin{bmatrix} \sqrt{5} \\ 0 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \\ 0 \\ 0 \end{bmatrix}$

- 每个Givens旋转阵用参数c, s刻画
- 每次旋转变换仅影响向量两个元素, 仅影响矩阵的两行
- 也可实现矩阵的**QR**分解, 适合于稀疏矩阵



QR迭代算法

计算矩阵的所有特征值

■ 两个问题

□ 什么样的矩阵易于求所有特征值?

□ 对矩阵做怎样的变换能保持特征值不变?

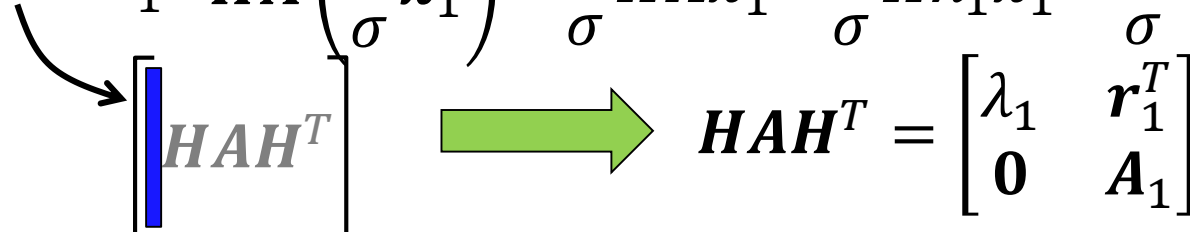
$$X^{-1}AX$$
$$Q^T A Q$$

■ 思路：用正交相似变换化矩阵为三角阵或分块三角阵

■ 收缩技术

□ 用幂法/反幂法已求出 A 的一个特征值 λ_1 , 特征向量 x_1

□ 构造变换对 x_1 消元: $Hx_1 = \sigma e_1$, 再对 A 做正交相似变换

$$HAH^T e_1 = HA \left(\frac{1}{\sigma} x_1 \right) = \frac{1}{\sigma} H A x_1 = \frac{1}{\sigma} H \lambda_1 x_1 = \frac{\lambda_1}{\sigma} (\sigma e_1) = \lambda_1 e_1$$

$$HAH^T = \begin{bmatrix} \lambda_1 & r_1^T \\ \mathbf{0} & A_1 \end{bmatrix}$$

计算矩阵的所有特征值

■ 收缩技术的例子: 已知 $A = \begin{bmatrix} 3 & -1 & 1 \\ 2 & 0 & 1 \\ 1 & -1 & 2 \end{bmatrix}$ 的一个特征值为

$\lambda_1 = 2$, 对应特征向量为 $x_1 = [1, 1, 0]^T$, 求其他特征值

解: 用Householder变换对 x_1 消元, 相应的 $\sigma = \sqrt{2} = 1.4142$

构造矩阵 H 的 v 向量为: $v = x_1 + \sigma e_1 = \begin{bmatrix} 2.4142 \\ 1 \\ 0 \end{bmatrix}$

$$\Rightarrow H = \begin{bmatrix} -0.7072 & -0.7072 & 0 \\ -0.7072 & 0.7072 & 0 \\ 0 & 0 & 1 \end{bmatrix}, HAH^T = \begin{bmatrix} 2 & 3 & -1.4142 \\ 0 & 1 & 0 \\ 0 & -1.4142 & 2 \end{bmatrix} \quad A_1$$

易知 A_1 的特征值为 1 和 2, 是 A 的其他特征值

□ 根据的 A_1 特征向量, 还可求 A 的特征向量

□ 不形成 H 计算 HAH^T : 先算 $B = HA^T$, 再 $HAH^T = HB^T$

QR迭代算法

■ 理论基础

- 用一系列正交相似变换 $B = Q^T A Q$, 逐渐将矩阵 A 化为上三角或对角块阶数很小的分块上三角矩阵
- 设 $A \in \mathbb{R}^{n \times n}$, 若 A 为分块上三角阵, 且对角块为1阶或2阶矩阵, 则称 A 为拟上三角阵, 也叫实Schur型
- **Th5.21 (Schur分解):** $\forall A \in \mathbb{R}^{n \times n}$, \exists 正交阵 Q 使 $Q^T A Q = S$, 其中 S 为拟上三角阵, 其一阶对角块是 A 的实特征值, 二阶对角块的特征值是 A 的两个共轭复特征值

■ QR算法 (“二十世纪十大算法”之一)

$\left\{ \begin{array}{l} \text{对 } A_k \text{ 做QR分解: } A_k = Q_k R_k \\ A_{k+1} = R_k Q_k, (k = 0, 1, \dots) \end{array} \right.$ 生成正交相似矩阵序列 $\{A_k\}$

QR迭代算法

■ Th5.22: 收敛定理

- 矩阵 A 满足一定条件, 则
QR迭代所得矩阵序列 $\{A_k\}$
基本收敛于拟上三角阵

拟上三角阵例子? “基本收敛”

$$\begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ & \times & \times & \times \\ & & \times & \times \end{bmatrix} \text{ or } \begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & 0 & \times \end{bmatrix}$$

算法5.4: 计算矩阵特征值的QR算法

输入: A ; 输出: $\lambda_1, \dots, \lambda_n$.

While A 不是拟上三角阵 **do**

 计算 A 的QR分解, 得到矩阵 Q 和 R ;

$A := RQ$;

End

根据 A 的对角块求特征值 $\lambda_1, \dots, \lambda_n$.

课本pp.173的例5.13

正交相似变换是保对称性的, A 对称, 则 $Q^T A Q$ 也对称

对对称阵做QR迭代, 若收敛, 极限为块对角阵(块阶 ≤ 2)

实用的QR迭代技术

■ QR迭代法的不足之处

- 每步迭代的计算量很大 将矩阵化简为上Hessenberg型
- 可能不收敛, 或收敛很慢 带原点位移的QR算法

■ 上Hessenberg约化

- 上Hessenberg阵:

$$\begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ & \times & \times & \times \\ & & \times & \times \end{bmatrix}$$

- 将A正交相似约化为上Hessenberg阵, 再做QR分解(迭代), 用Givens旋转, 每步计算由 $O(n^3)$ 降为 $O(n^2)$

设 P_1, P_2, \dots, P_{n-1} 为Givens旋转阵, A_k 为上Hessenberg阵

$$P_{n-1} \cdots P_2 P_1 A_k = R_k \Rightarrow Q_k = (P_{n-1} \cdots P_2 P_1)^T$$

$$A_{k+1} = R_k Q_k = P_{n-1} \cdots P_2 P_1 A_k (P_{n-1} \cdots P_2 P_1)^T$$

$$= P_{n-1} \cdots P_2 P_1 A_k P_1^T P_2^T \cdots P_{n-1}^T$$

思考: 证明 A_{k+1} 仍是上Hessenberg阵

实用的QR迭代技术

- 将A正交相似约化为上Hessengberg

- 用Householder变换

$$\begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \end{bmatrix} \rightarrow \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ & \times & \times & \times & \times \\ & & \times & \times & \times \\ & & & \times & \times \end{bmatrix}$$

$$A = \begin{bmatrix} a_{11} & \mathbf{r}_1^T \\ \mathbf{c}_1 & A_{22}^{(1)} \end{bmatrix} \xrightarrow{H_1 = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & H'_1 \end{bmatrix}} H_1 A = \begin{bmatrix} a_{11} & \mathbf{r}_1^T \\ \sigma_1 \mathbf{e}_1 & H'_1 A_{22}^{(1)} \end{bmatrix} \rightarrow H_1 A H_1 = \begin{bmatrix} a_{11} & \mathbf{r}_1^T H'_1 \\ \sigma_1 \mathbf{e}_1 & H'_1 A_{22}^{(1)} H'_1 \end{bmatrix}$$


$$A^{(2)} = H_1 A H_1 = \begin{bmatrix} A_{11}^{(2)} & A_{12}^{(2)} \\ A_{21}^{(2)} & A_{22}^{(2)} \end{bmatrix} \xrightarrow{H_2 = \begin{bmatrix} I_2 & \mathbf{0}^T \\ \mathbf{0} & H'_2 \end{bmatrix}} H_2 A^{(2)} H_2 = \begin{bmatrix} a_{11} & a_{12}^{(2)} & a_{13}^{(3)} & \cdots & \cdots & a_{1n}^{(3)} \\ \sigma_1 & a_{22}^{(2)} & a_{23}^{(3)} & \cdots & \cdots & a_{2n}^{(3)} \\ \hline 0 & \sigma_2 & a_{33}^{(3)} & \cdots & \cdots & a_{3n}^{(3)} \\ 0 & 0 & \vdots & \ddots & & \vdots \\ \vdots & \vdots & \vdots & & \ddots & \vdots \\ 0 & 0 & a_{n3}^{(3)} & \cdots & \cdots & a_{nn}^{(3)} \end{bmatrix}$$

... ..

- 最终 $H_{n-2} \cdots H_1 A H_1 \cdots H_{n-2}$ 为上Hessenberg阵

实用的QR迭代技术

- 实对称矩阵 A



- 带原点位移的QR算法

- 单位移技术 $\begin{cases} Q_k R_k = A_k - s_k I, & (\text{作QR分解}) \\ A_{k+1} = R_k Q_k + s_k I, & k = 1, 2, \dots \end{cases}$

$$A_{k+1} = R_k Q_k + s_k I$$

$$= Q_k^T (A_k - s_k I) Q_k + s_k I = Q_k^T A_k Q_k \longrightarrow \{A_k\} \text{ 仍两两正交相似}$$

- 简单的Rayleigh策略: 取 $s_k = A_k(n, n)$, 加速收敛


- 非对称阵有复特征值, 采用双位移

- Matlab命令: **qr, eig, eigs, planerot**

Matlab演示,
eiggui



- G. H. Golub, C. F. Van Loan. *Matrix Computations* (3rd edition), Johns Hopkins University Press, 1996.



Matrix Computations

THIRD EDITION

Gene H. Golub

*Department of Computer Science
Stanford University*

Charles F. Van Loan

*Department of Computer Science
Cornell University*

- iii -

DEDICATED TO

ALSTON S. HOUSEHOLDER

AND

JAMES H. WILKINSON

- vi -

<http://www.cs.cornell.edu/cv/>

label: **Hollywood**

